


检索与上下文构建效率

平均响应时间

约 5.2 倍加速

响应时间缩短 80.7%



12 个 Java / TypeScript 函数定位任务，每组重复 3 次；预热后测量。

同一索引、模型与硬件，两轮实测；统计从提交查询到返回 Context 的完整响应时间。

旧版：4,000 Token 上限；新版：默认不设内容上限。