


检索并行化效率

平均响应时间

响应时间缩短 16.9%

相同候选与上下文输出



12 个 Java / TypeScript 函数定位任务，每组重复 5 次；预热后测量。

同一索引、模型与硬件，交替运行；统计从提交查询到返回 Context 的完整响应时间。

两组均不设内容上限；声明、正文和摘要通道分别串行或并行执行。